


三星 諒太郎九州大学/理研AIP
ryotaro.mitsuboshi@inf.kyushu-u.ac.jp

畑埜 晃平九州大学/理研AIP
hatano@inf.kyushu-u.ac.jp

オンライン組合せ線形最適化

各ラウンド $t = 1, 2, \dots, T$ において：



目標.

α -リグレット $R_T \triangleq \sum_{t=1}^T c_t \cdot \ell_t - \alpha \min_{c \in \mathcal{C}} \sum_{t=1}^T c \cdot \ell_t$ の最小化

- 決定集合 $\mathcal{C} \subset \mathbb{R}_+^n$ が離散集合なので難しい。
- 応用例：オンライン集合被覆，オンライン巡回セールスマン，等。

先行研究

一般に，組合せ集合上の最適化問題を解くのは困難。
 \mathcal{C} 上の α -近似オラクル $\mathcal{O}_{\mathcal{C}}: \mathbb{R}^n \rightarrow \mathcal{C}$ が存在することを仮定。

$$\forall \ell \in \mathbb{R}^n, \quad \mathcal{O}_{\mathcal{C}}(\ell) \cdot \ell \leq \alpha \min_{c \in \mathcal{C}} c \cdot \ell$$

手法	近似アルゴリズム	1 ラウンドあたりの オラクル呼出回数	リグレット
Garber 2017	何でも良い	$O(n^2 \ln T)$	$O(T^{2/3})$
Garber 2017	何でも良い	$O(n^2 \sqrt{T} \ln T)$	$O(T^{1/2})$
Fujita et al. 2013	緩和ベース	$O(L^2 D_{\infty}^2 \ln(Ln)/\epsilon^2)$	$O(T^{1/2})$
本研究	緩和ベース	$O(D_{\infty}^2 \ln(n)/\epsilon^2)$	$O(T^{1/2})$

L は Fujita et al., 2013 中で扱う最適化問題の双対解の L_1 -ノルム，
 $D_{\infty} = \max_{c \in \mathcal{C}} \|c\|_{\infty}$ 。

提案手法は

- Fujita et al. 2013 と同じ仮定のもと，オラクル呼出回数を改善。
- ラウンド数 T や α の値を知らなくて良い(Garber, 2017 では必要)。

オフラインでの緩和に基づくアプローチ [Fujita et al., 13]

緩和に基づく α -近似オラクル $\mathcal{R}_{\text{relax}(\mathcal{C})}: \mathbb{R}_+^n \rightarrow \mathcal{C}$ を仮定。


$\mathcal{R}_{\text{relax}(\mathcal{C})}$ は $\ell \in \mathbb{R}_+^n$ を与えると次のように動作：

- \mathcal{C} を含む閉凸集合 $\text{relax}(\mathcal{C}) \supset \mathcal{C}$ を構成。
- $\text{relax}(\mathcal{C})$ 上で線形最適化。

$$x \in \arg \min_{x \in \text{relax}(\mathcal{C})} x \cdot \ell$$

- x を基に「良い」実行可能解 $c \in \mathcal{C}$ を構成。
(α -近似アルゴリズム)

$$\text{Find } c \in \mathcal{C} \quad \text{s.t.} \quad c \cdot \ell \leq \alpha x \cdot \ell$$



オンラインでは $c \in \mathcal{C}$ を決めた後に ℓ を観測。
どんな $\ell \in \mathbb{R}_+^n$ が来ても良いようにする（メタラウンディング）。

メタラウンディング


アルゴリズム $\mathcal{M}: \text{relax}(\mathcal{C}) \rightarrow \mathcal{C}$ がメタラウンディングである

$$\iff \forall \ell \in \mathbb{R}_+^n, \quad \mathbb{E}[\mathcal{M}(x)] \cdot \ell \leq \alpha x \cdot \ell$$

ここで，期待値は \mathcal{M} 内部の確率変数上で取られる。

定理 [Fujita et al., 13]

\mathcal{M} が存在 $\implies R_T = O(\sqrt{T})$ であるアルゴリズムが存在。



α が未知の場合，次の最適化問題の最適解 λ に従って $c \in \mathcal{C}$ を選べばメタラウンディングになる。

$$\begin{array}{ll} \min_{\beta, \lambda} \beta & (1) \\ \text{s.t. } \mathbb{E}_{c \sim \lambda}[c] = \sum_{c \in \mathcal{C}} \lambda_c c \leq \beta x, \\ \|\lambda\|_1 = 1, \quad \lambda \geq 0 \end{array} \quad \left| \quad \begin{array}{ll} \max_{\gamma, \ell} \gamma & (2) \\ \text{s.t. } \ell \cdot c \geq \gamma, \quad \forall c \in \mathcal{C}, \\ \ell \cdot x = 1, \quad \ell \geq 0 \end{array} \right.$$

[Fujita et al., '13] では，

- (1) をブースティングとして捉え，
- 双対問題 (2) を解くアルゴリズムを提案し解析。

瀧本 英二九州大学
eiji@inf.kyushu-u.ac.jp



提案手法

本研究では，

- ERLPBoost [Warmuth et al., 08] を基にしたアルゴリズムを提案。
 - 解析はフランク・ウルフ法のテクニック [Jaggi, '13] で行う。
- 解析をするために，(2) に**エントロピーのような関数**を正則化。

$$\max_{\gamma, \ell} \gamma - \frac{1}{\eta} \sum_{i=1}^n \ell_i x_i \ln \frac{\ell_i x_i}{1/n} \quad \text{subject to} \quad \ell \cdot c \geq \gamma, \quad \forall c \in \mathcal{C}, \quad (3)$$
$$\ell \cdot x = 1, \quad \ell \geq 0.$$

次の手順を実行することで，(1) の ϵ -近似解を求める。

- $\mathcal{C}_0 := \emptyset$ から始め，
- 各ラウンド $k = 0, 1, 2, \dots, K$ において
 \mathcal{C}_k 上での (3) の最適解を ℓ_k とし， $\mathcal{C}_{k+1} := \mathcal{C}_k \cup \{\mathcal{R}_{\text{relax}(\mathcal{C})}(\ell_k)\}$ とする。
- \mathcal{C}_{K+1} 上で (1) を解き，得られた $\lambda \in [0, 1]^{\mathcal{C}_K}$ に従って $c \in \mathcal{C}_K$ を出力。

主結果

$\eta \geq 2 \ln(n)/\epsilon$ を満たすように設定すれば，提案アルゴリズムは高々 $\lceil 32 D_{\infty}^2 \ln(n)/\epsilon^2 \rceil$ 回の反復の後 (1) の ϵ -近似解を見つける。

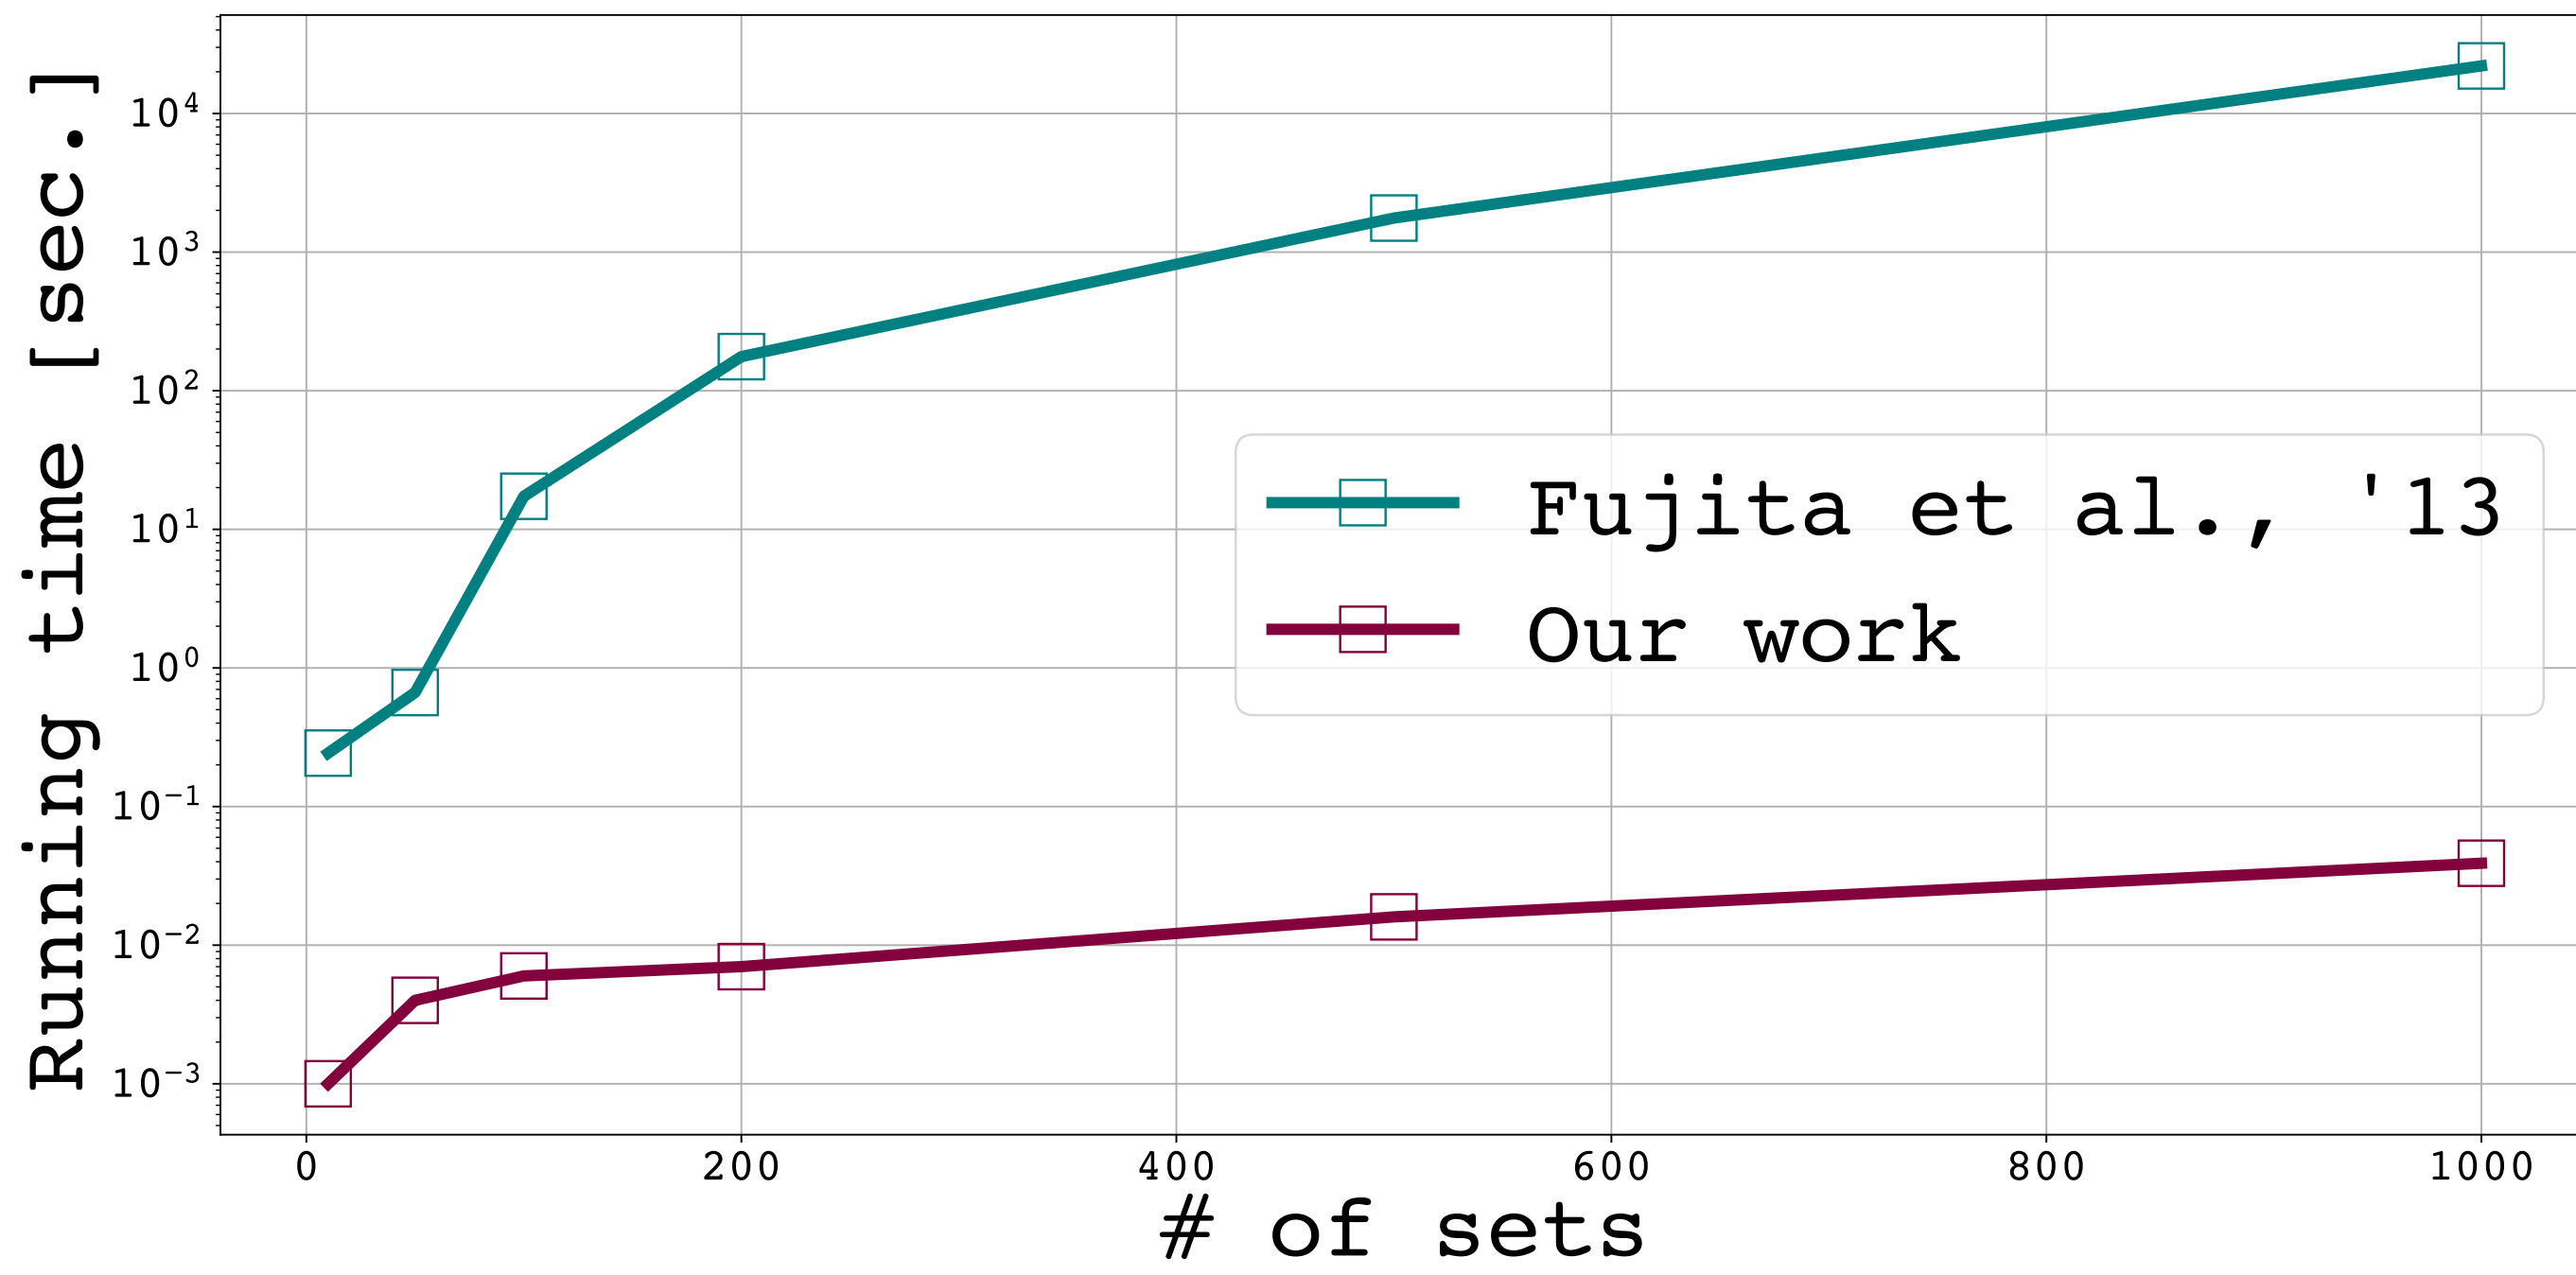
Note:

- 提案アルゴリズムは ERLPBoost の一般化 ($x = 1$ で ERLPBoost)。
- 先行研究 [Fujita et al., '13] 同様，**真の近似率 α やラウンド数 T を知らなくて良い**。
- (3) の Fenchel 双対問題は双対ギャップ 0 で，その目的関数は平滑。
- 提案手法は，(3) の双対問題をフランク・ウルフ法で解いている。
- 実際には適切な停止条件が設定されているので，多くの場合最大まで回す必要はない。
- α の上界を用いる先行研究 [Kakade et al., '09; Garber, '17] と異なり，より正確な α を計算できるのでリグレットが小さくなることが期待できる。

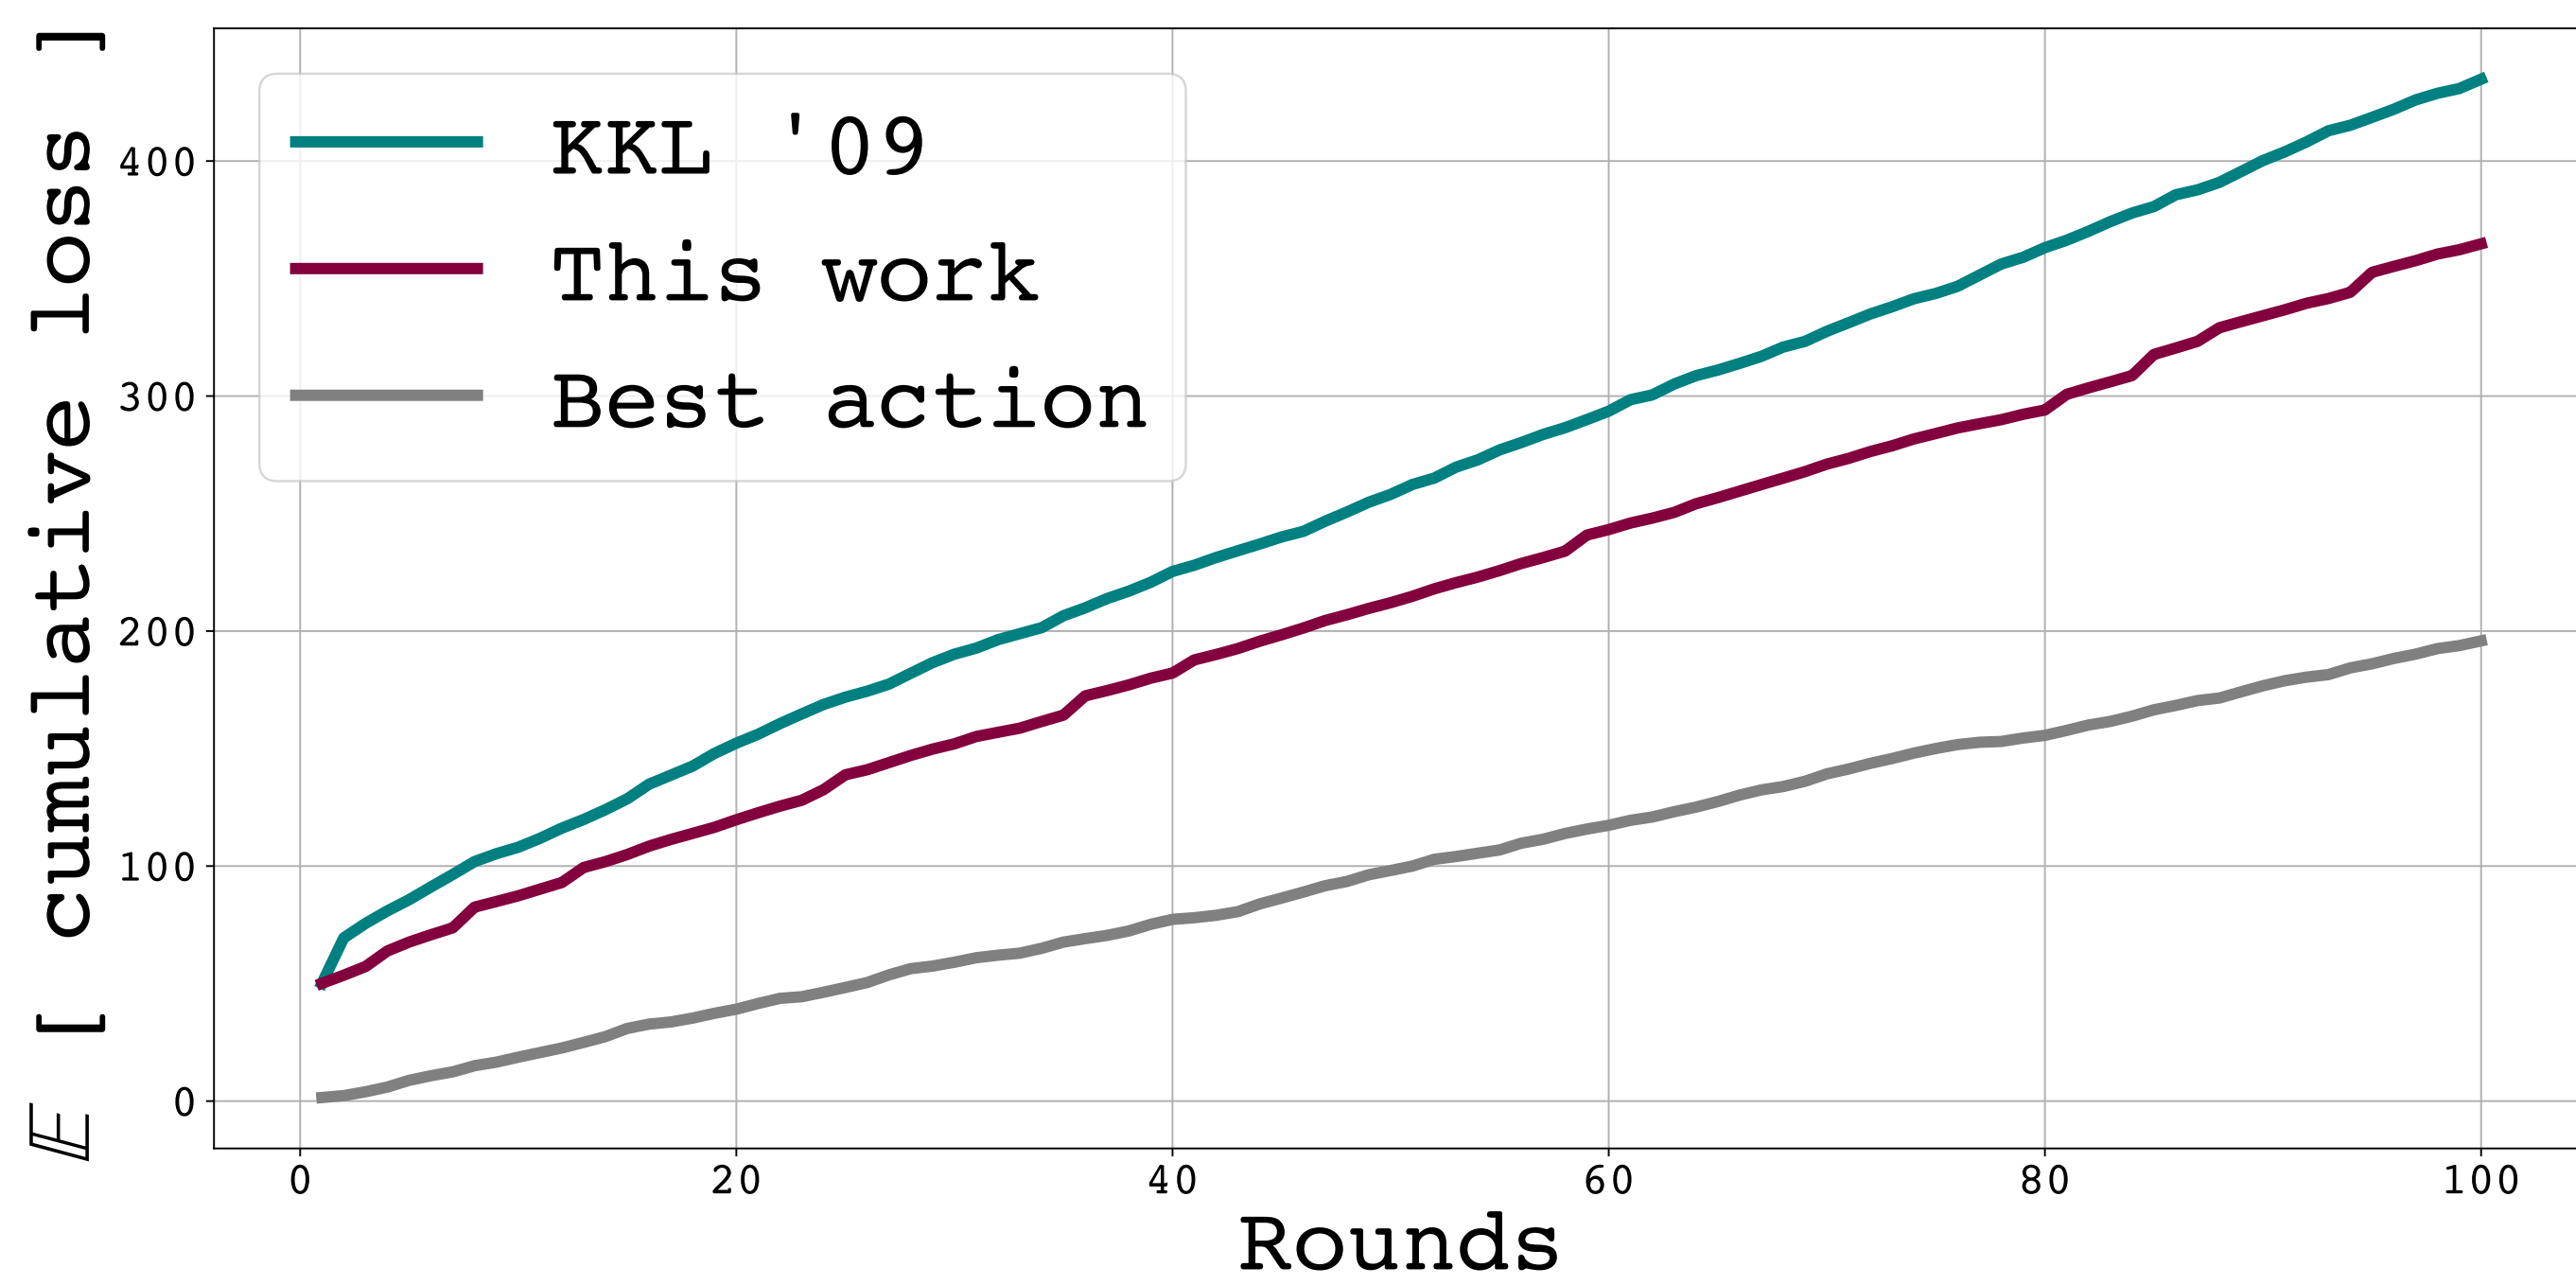
実験

人工的に生成した集合被覆のデータ上で実験 ($n = 20$) 。

- メタラウンディングの時間比較．vs. [Fujita et al., '13]



- 累積損失の比較．vs. [Kakade et al., '09]
([Garber '17] は実装が間に合わず，その一つ前の手法と比較)
損失ベクトルはランダムに生成し， $|\mathcal{C}| = 100$ で実験。
どちらもリグレット保証は同じ． $R_T = O(\sqrt{T})$ 。



まとめ

- 本研究では， $\mathcal{R}_{\text{relax}(\mathcal{C})}$ の存在を仮定した上でより効率的なメタラウンディングを提案。
 - 数値実験で有効性を確認。
- 数値実験で，[Kakade et al., '17] の結果より優れた累積損失を達成。
- 提案アルゴリズムは ERLPBoost [Warmuth et al., '08] の一般化。
- 提案アルゴリズムは近似率 α やラウンド数 T を知らなくて良い。